



République Algérienne Démocratique et Populaire

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Université des Sciences et de la Technologie Houari Boumediene

Faculté d'Informatique

Département d'Intelligence Artificielle et Science des Données

---

Rapport du module : Introduction à l'Intelligence Artificielle

L'Apprentissage Supervisé

Réalisé par :

Boumaraf Yasmine
Hamdi Amine
Aoun Younes
Diffallah Rachid
Saou Yanis

Encadré par :

Mme Oulefki

Table des matières

Résumé du projet **3**

Introduction générale **4**

1 Introduction au Machine Learning **5**
1.1 Définition du Machine Learning 5
1.2 Types d'apprentissage automatique 5
1.2.1 L'apprentissage supervisé 5
1.2.2 Apprentissage non supervisé 6
1.2.3 Apprentissage par renforcement 6
1.3 Apprentissage supervisé 6
1.4 Notions clés 7

2 Pipeline du Machine Learning **7**
2.1 Introduction 7
2.2 Principe général du pipeline 8
2.3 Les étapes du pipeline 8
2.3.1 Les étapes du pipeline 8
2.3.2 Préparation des données 8
2.3.3 Séparation des données 8
2.3.4 Entraînement du modèle 8
2.3.5 Évaluation du modèle 9
2.3.6 Prédiction 9
2.4 Lien avec notre présentation 9
2.5 Conclusion 9

3 Régression et Classification **10**
3.1 Introduction 10
3.2 La Régression 10
3.2.1 Définition 10
3.2.2 Fonctionnement 10
3.2.3 Modèles utilisés 11
3.2.4 Évaluation 11
3.3 La Classification 11

3.3.1 Définition 11
3.3.2 Fonctionnement 11
3.3.3 Modèles utilisés 11
3.3.4 Évaluation 12
3.4 Comparaison entre Régression et Classification 12
3.5 Conclusion 12

4 L'Overfitting (Sur-apprentissage) 13
4.1 Définition 13
4.2 Comment détecter l'overfitting ? 13
4.3 Les causes de l'overfitting 14
4.4 Solution : Le Random Forest 14

5 Exemple Réel — Prédiction de Résultats de Football 15
5.1 Présentation 15
5.2 Étape 1 — Les données 15
5.3 Étape 2 et 3 — Division des données et Entraînement 16
5.4 Étape 4 — Évaluation du modèle 16
5.5 Applications réelles 17

conclusion 18

Liste des tableaux

4.1 Comparaison des performances selon le type de modèle (underfitting, bon modèle, overfitting) 13

5.1 Description des features utilisées pour la prédiction des matchs de football . . . 15
5.2 Exemple de vote majoritaire dans un Random Forest (100 arbres) 16
5.3 Résultats globaux du modèle Random Forest (train vs test accuracy) 16
5.4 Matrice de confusion du modèle de classification des résultats de matchs . . . 17

Résumé du projet

Ce projet traite de l'apprentissage supervisé, une branche essentielle du Machine Learning dans le domaine de l'intelligence artificielle. Il vise à comprendre comment un modèle peut apprendre à partir de données étiquetées afin de réaliser des prédictions fiables.

Le travail présente d'abord les bases de l'intelligence artificielle et les principaux types d'apprentissage automatique, avec un accent sur l'apprentissage supervisé. Il décrit ensuite le pipeline du Machine Learning, qui regroupe les étapes clés : collecte, préparation des données, entraînement, évaluation et prédiction.

Le projet aborde également les notions de régression et de classification, ainsi que le problème du surapprentissage (overfitting) et ses solutions, notamment le Random Forest.

Enfin, une application concrète est réalisée sur la prédiction des résultats de matchs de football, montrant de bonnes performances du modèle et une bonne capacité de généralisation.

Introduction générale

L'intelligence artificielle (IA) est un domaine de l'informatique qui vise à concevoir des systèmes capables d'imiter certaines capacités humaines, telles que l'apprentissage, l'analyse des données et la prise de décision. Au cours des dernières années, l'IA a connu un développement rapide et est aujourd'hui utilisée dans de nombreux domaines, notamment la reconnaissance d'images, la reconnaissance vocale, les véhicules autonomes et les systèmes de recommandation. Parmi les branches les plus importantes de l'intelligence artificielle, on trouve le Machine Learning, ou apprentissage automatique, qui permet aux machines d'apprendre à partir des données sans être explicitement programmées. Cette approche repose sur l'analyse de grandes quantités de données afin de détecter des modèles et d'effectuer des prédictions. Dans ce contexte, l'apprentissage supervisé constitue l'une des techniques les plus utilisées en Machine Learning. Il repose sur l'utilisation de données étiquetées, où chaque entrée est associée à une sortie connue, afin d'apprendre une fonction permettant de prédire des résultats pour de nouvelles données. L'objectif de ce projet est de présenter les principes fondamentaux de l'apprentissage supervisé, ainsi que ses principales applications. Pour illustrer ces concepts, nous nous appuierons sur un exemple simple : les systèmes de recommandation, qui permettent de proposer du contenu personnalisé aux utilisateurs en fonction de leurs préférences, notamment dans des domaines tels que les plateformes de streaming, le commerce en ligne ou encore les paris sportifs.

Chapitre 1

Introduction au Machine Learning

1.1 Définition du Machine Learning

Le Machine Learning, ou apprentissage automatique, s'inscrit au cœur de l'intelligence artificielle moderne. Son objectif est simple en apparence, mais profond dans ses implications : permettre aux machines d'apprendre à partir des données. Il ne s'agit plus de définir explicitement chaque règle. Le système observe, analyse, puis s'adapte. Concrètement, il repose sur des méthodes statistiques et algorithmiques capables d'exploiter de grandes quantités de données. À partir de celles-ci, il identifie des régularités, parfois invisibles à l'œil humain. Ces motifs deviennent alors la base de modèles capables de prédire, de décider ou d'anticiper. Mais apprendre ne signifie pas mémoriser. C'est là toute la nuance. Un bon modèle ne se contente pas de reproduire ce qu'il a vu. Il généralise. Il fait face à des situations nouvelles et propose des réponses cohérentes. Progressivement, ses performances s'améliorent. Ainsi, le Machine Learning peut être vu comme un processus évolutif, où les données deviennent une source de connaissance et où chaque itération affine la compréhension du système.

1.2 Types d'apprentissage automatique

L'apprentissage automatique ne se limite pas à une seule approche. Il regroupe plusieurs méthodes, chacune reposant sur une manière différente d'exploiter les données. Certaines méthodes apprennent à partir d'exemples guidés, d'autres explorent les structures cachées, tandis que d'autres apprennent par interaction avec un environnement.
Comprendre ces différences est essentiel pour saisir la logique globale du Machine Learning.

1.2.1 L'apprentissage supervisé

Apprentissage supervisé est sans doute l'approche la plus intuitive. Ici, le modèle apprend à partir de données déjà annotées. Chaque exemple est associé à une réponse correcte, ce qui guide le processus d'apprentissage. Au début, le modèle se trompe. C'est normal. Il compare ses prédictions aux résultats attendus, ajuste ses paramètres, puis réessaie. Progressivement, il

s'améliore et parvient à comprendre la relation entre les entrées et les sorties.
L'objectif est clair : apprendre une fonction permettant de prédire correctement sur de nouvelles données. Une fois entraîné, le modèle devient capable de généraliser et de traiter des situations inconnues.

1.2.2 Apprentissage non supervisé

Avec l'apprentissage non supervisé, le contexte change complètement. Il n'existe plus de réponses correctes ni d'étiquettes pour guider le modèle. Le système doit alors explorer les données par lui-même. Il cherche des structures, des regroupements et des similarités. Son but est d'organiser l'information de manière cohérente sans intervention humaine directe. C'est une approche plus libre, mais aussi plus complexe, car le modèle ne reçoit aucun retour explicite sur ses performances.

1.2.3 Apprentissage par renforcement

L'apprentissage par renforcement introduit une dimension différente : l'interaction avec un environnement. Le modèle, appelé agent, prend des décisions, observe les conséquences et reçoit des récompenses ou des pénalités. À partir de ces retours, il ajuste progressivement son comportement. C'est un processus dynamique basé sur l'essai et l'erreur. Le modèle explore différentes stratégies et retient celles qui maximisent les récompenses sur le long terme. Cette approche est particulièrement utilisée en robotique, dans les jeux et les systèmes autonomes.

1.3 Apprentissage supervisé

Parmi les différentes approches du Machine Learning, l'apprentissage supervisé occupe une place centrale. Il se distingue par sa simplicité conceptuelle et son efficacité. Chaque exemple d'entraînement est accompagné d'une étiquette représentant la réponse attendue. Le modèle observe ces associations entre entrées et sorties, puis apprend progressivement à les reproduire. Au fil du temps, il ajuste ses paramètres afin de réduire l'erreur entre ses prédictions et les valeurs réelles. Ce processus lui permet de construire une relation fiable entre les variables d'entrée et la variable cible. Cependant, un équilibre est nécessaire. Un apprentissage excessif peut conduire à une mémorisation des données, tandis qu'un apprentissage insuffisant limite la précision du modèle. L'objectif final est donc d'atteindre une bonne capacité de généralisation.

1.4 Notions clés

Pour comprendre l'apprentissage supervisé, certaines notions fondamentales doivent être maîtrisées. Elles constituent la base de tout modèle d'apprentissage automatique.

— **Données d'entraînement**
Les données d'entraînement représentent l'ensemble des exemples utilisés pour apprendre au modèle. Elles contiennent les informations nécessaires pour établir des relations entre les variables. Plus ces données sont riches et de qualité, plus le modèle sera performant. Elles constituent le point de départ de tout processus d'apprentissage.

— **Features (caractéristiques)**
Les features, ou caractéristiques, correspondent aux variables d'entrée du modèle. Elles décrivent les observations et fournissent les informations nécessaires pour effectuer une prédiction. Chaque feature apporte une partie de l'information. Ensemble, elles permettent au modèle de comprendre le problème dans sa globalité. Leur sélection est une étape cruciale dans la construction d'un bon modèle.

— **Modèle** Le modèle est l'élément central du système d'apprentissage. Il s'agit d'un algorithme capable de transformer des données d'entrée en prédictions. Pendant la phase d'entraînement, il ajuste ses paramètres afin de minimiser l'écart entre les valeurs prédites et les valeurs réelles. Une fois entraîné, il peut être utilisé sur de nouvelles données. Un bon modèle ne se contente pas d'apprendre. Il est capable de généraliser.

Chapitre 2

Pipeline du Machine Learning

2.1 Introduction

Le pipeline du Machine Learning représente l'ensemble des étapes qui permettent de transformer des données brutes en un modèle capable de faire des prédictions. Il s'agit d'un processus organisé qui guide toutes les phases du projet, depuis la collecte des données jusqu'à leur utilisation dans un contexte réel. Dans notre présentation, nous avons choisi de simplifier ce concept en le représentant sous forme d'un schéma. L'objectif était de rendre le pipeline plus compréhensible, sans entrer dans des détails trop techniques.

2.2 Principe général du pipeline

De manière générale, un pipeline ML suit toujours la même logique : données → préparation → apprentissage → évaluation → prédiction Chaque étape dépend de la précédente, ce qui signifie qu'une erreur au début peut affecter tout le reste du processus. L'intérêt du pipeline est donc de structurer le travail et de garantir que toutes les étapes sont bien réalisées dans le bon ordre.

2.3 Les étapes du pipeline

2.3.1 Les étapes du pipeline

La première étape consiste à récupérer les données qui seront utilisées pour entraîner le modèle. Ces données peuvent provenir de différentes sources, comme des fichiers, des bases de données ou des API.

2.3.2 Préparation des données

Les données collectées ne sont généralement pas directement utilisables. Elles peuvent contenir des erreurs, des valeurs manquantes ou des formats différents. Il est donc nécessaire de les nettoyer et de les transformer. Par exemple, certaines variables doivent être converties en valeurs numériques pour être utilisées par le modèle.

2.3.3 Séparation des données

Une fois les données prêtes, elles sont divisées en deux parties :

— les données d'entraînement (training set)

— les données de test (test set)

Le modèle apprend uniquement sur les données d'entraînement, tandis que les données de test servent à vérifier ses performances.

2.3.4 Entraînement du modèle

Cette étape consiste à appliquer un algorithme aux données d'entraînement afin que le modèle puisse apprendre les relations entre les variables. Le modèle va progressivement ajuster ses paramètres pour réduire les erreurs entre ses prédictions et les valeurs réelles.

2.3.5 Évaluation du modèle

Une fois le modèle entraîné, il est important de vérifier sa performance. Pour cela, on utilise les données de test. Cette étape permet de savoir si le modèle est capable de généraliser, c'est-à-dire de fonctionner correctement sur de nouvelles données.

2.3.6 Prédiction

La dernière étape du pipeline consiste à utiliser le modèle pour faire des prédictions sur de nouvelles données. C'est à ce moment que le modèle devient réellement utile, car il peut être appliqué dans des situations concrètes.

2.4 Lien avec notre présentation

Dans notre travail, nous avons volontairement simplifié le pipeline afin de le rendre plus clair. Nous avons utilisé un schéma simple montrant les différentes étapes, plutôt que d'entrer dans des détails techniques. L'objectif n'était pas de présenter un pipeline complexe, mais de comprendre son fonctionnement global et son importance dans un projet de Machine Learning.

2.5 Conclusion

Le pipeline du Machine Learning est une étape essentielle dans tout projet d'apprentissage supervisé. Il permet d'organiser le travail, de structurer les données et d'assurer la qualité des résultats.

Chapitre 3

Régression et Classification

3.1 Introduction

Dans le cadre de l'apprentissage supervisé, on distingue principalement deux types de problèmes : la régression et la classification. Ces deux approches reposent sur le même principe général : un modèle apprend à partir de données étiquetées afin de faire des prédictions sur de nouvelles données. La différence principale entre les deux réside dans la nature de la sortie. Dans un problème de régression, la sortie est une valeur numérique continue, alors que dans un problème de classification, la sortie correspond à une catégorie. Dans notre présentation, nous avons choisi de regrouper ces deux notions afin de montrer leur complémentarité et de faciliter leur compréhension.

3.2 La Régression

3.2.1 Définition

La régression est une méthode d'apprentissage supervisé utilisée pour prédire une valeur numérique. Elle permet d'estimer une variable continue à partir d'un ensemble de variables d'entrée. Par exemple, on peut utiliser la régression pour prédire le prix d'un logement en fonction de sa surface, du nombre de pièces ou encore de sa localisation.

3.2.2 Fonctionnement

Le principe de la régression consiste à trouver une relation entre les variables d'entrée et la variable de sortie. Le modèle apprend cette relation à partir des données d'entraînement, puis il l'utilise pour faire des prédictions. Dans notre présentation, nous avons illustré ce fonctionnement avec un exemple simple où la surface d'un logement permet d'estimer son prix. Cela permet de visualiser facilement la relation entre une variable explicative et la valeur à prédire.

3.2.3 Modèles utilisés

Plusieurs algorithmes peuvent être utilisés pour résoudre des problèmes de régression. Parmi les plus simples, on retrouve la régression linéaire, qui modélise la relation entre les variables sous forme d'une droite. D'autres modèles plus avancés existent, comme les arbres de décision ou les forêts aléatoires, qui permettent de capturer des relations plus complexes entre les données. Dans notre travail, nous avons volontairement simplifié ces modèles afin de nous concentrer sur le principe général plutôt que sur les détails mathématiques.

3.2.4 Évaluation

Pour évaluer un modèle de régression, on utilise des métriques qui mesurent l'écart entre les valeurs prédites et les valeurs réelles. Par exemple, l'erreur quadratique moyenne (MSE) ou la racine de cette erreur (RMSE) permettent de quantifier la précision du modèle. Ces indicateurs nous permettent de vérifier si le modèle est fiable et s'il peut être utilisé dans un contexte réel.

3.3 La Classification

3.3.1 Définition

La classification est une méthode d'apprentissage supervisé qui permet de prédire une catégorie. Contrairement à la régression, la sortie du modèle est une classe appartenant à un ensemble limité. Par exemple, un modèle peut déterminer si un email est un spam ou non, ou encore classifier un film selon son genre.

3.3.2 Fonctionnement

Le fonctionnement de la classification repose sur l'apprentissage de patterns dans les données. Le modèle analyse les exemples d'entraînement et apprend à associer certaines caractéristiques à une classe donnée. Dans notre présentation, nous avons utilisé des exemples simples comme la détection de spam ou la classification de films afin de rendre ce concept plus concret.

3.3.3 Modèles utilisés

Il existe plusieurs algorithmes de classification, comme la régression logistique, les k plus proches voisins (KNN) ou encore les arbres de décision. Ces modèles permettent de séparer les données en différentes classes en fonction de leurs caractéristiques. Certains modèles sont simples et faciles à interpréter, tandis que d'autres sont plus performants mais plus complexes

3.3.4 Évaluation

L'évaluation d'un modèle de classification se fait généralement à l'aide de la matrice de confusion, qui permet de comparer les prédictions du modèle avec les valeurs réelles. On utilise ensuite des indicateurs comme l'accuracy, la précision ou le rappel pour mesurer la performance du modèle. Dans notre présentation, nous avons simplifié cette partie afin de rester cohérents avec le niveau du projet.

3.4 Comparaison entre Régression et Classification

Même si la régression et la classification ont des objectifs différents, elles reposent sur le même principe d'apprentissage supervisé. La principale différence concerne la nature de la sortie :

— la régression prédit une valeur numérique,

— la classification prédit une catégorie.

Dans les deux cas, le modèle suit les mêmes étapes : apprentissage, évaluation et prédiction.

3.5 Conclusion

La régression et la classification sont deux approches fondamentales en apprentissage supervisé. Elles permettent de répondre à différents types de problèmes en fonction de la nature des données. Dans notre travail, nous avons choisi de présenter ces concepts de manière simple et illustrée, afin de faciliter leur compréhension tout en restant cohérents avec notre présentation.

Chapitre 4

L'Overfitting (Sur-apprentissage)

4.1 Définition

L'overfitting est un phénomène qui se produit lorsqu'un modèle de Machine Learning s'adapte trop précisément aux données d'entraînement. Au lieu d'apprendre les tendances générales et les patterns importants, le modèle mémorise les exemples spécifiques, y compris le bruit et les anomalies.

Une analogie simple pour comprendre ce phénomène : imaginez un étudiant qui prépare un examen en mémorisant les réponses des anciens examens mot pour mot, sans chercher à comprendre les concepts. Le jour de l'examen, si le professeur pose des questions légèrement différentes, l'étudiant échoue — car il n'a pas vraiment appris, il a seulement mémorisé.

4.2 Comment détecter l'overfitting ?

Le signe principal de l'overfitting est une grande différence entre la précision sur les données d'entraînement (Train accuracy) et la précision sur les données de test (Test accuracy) :

TABLE 4.1 – Comparaison des performances selon le type de modèle (underfitting, bon modèle, overfitting)

Modèle	**Train Accuracy**	**Test Accuracy**	**Verdict**
Underfitting	55%	54%	Trop simple
Bon modèle	89%	86 %	Parfait !
Overfitting	99%	61%	A mémorisé !

Dans le cas de l'overfitting, on observe que le modèle atteint 99% de précision sur les données d'entraînement — ce qui semble excellent — mais chute à seulement 61% sur les données de test. Cette grande différence (38 points) révèle que le modèle a mémorisé les données au lieu d'apprendre.

4.3 Les causes de l'overfitting

Plusieurs facteurs peuvent provoquer l'overfitting :

— Modèle trop complexe : un modèle avec trop de paramètres peut s'adapter à chaque détail des données d'entraînement

— Données d'entraînement insuffisantes : avec peu de données, le modèle mémorise facilement

— Trop de features inutiles : des variables non pertinentes créent de fausses corrélations

— Entraînement trop long : le modèle continue d'apprendre les détails inutiles

4.4 Solution : Le Random Forest

L'un des solution pour corriger l'overfitting c'est le Random Forest. Au lieu d'utiliser un seul arbre de décision qui mémorise facilement, le Random Forest construit 100 arbres différents et les fait voter ensemble. Le résultat final est la décision majoritaire.

Chaque arbre est différent grâce à deux mécanismes :

— Le Bootstrapping : chaque arbre est entraîné sur un sous-ensemble différent des données, tiré aléatoirement avec remise.

— Les features aléatoires : à chaque nœud de l'arbre, seul un sous-ensemble aléatoire de features est considéré pour la décision.

Grâce à cette diversité, les erreurs de chaque arbre sont différentes et s'annulent lors du vote — ce qui réduit considérablement l'overfitting.

Chapitre 5

Exemple Réel — Prédiction de Résultats de Football

5.1 Présentation

Pour illustrer l'utilisation de l'apprentissage supervisé dans la vie réelle, nous avons choisi un exemple concret : prédire le résultat d'un match de football (Victoire, Défaite ou Nul) à partir de statistiques mesurables. Ce problème est un exemple typique de classification supervisée multi-classes, qui constitue l'un des concepts fondamentaux de l'apprentissage supervisé.

5.2 Étape 1 — Les données

Le dataset utilisé est le European Soccer Database, disponible sur la plateforme Kaggle. Il contient 10 000 matchs de football européen sur une période de 10 ans.

Pour chaque match, les features (variables d'entrée) utilisées sont :

TABLE 5.1 – Description des features utilisées pour la prédiction des matchs de football

Feature	**Description**
Buts marqués / match	Nombre de buts marqués par l'équipe
Buts encaissés / match	Nombre de buts encaissés par l'équipe
Possession moyenne (%)	Pourcentage de possession du ballon
Tirs cadrés / match	Nombre de tirs cadrés par match
Joueurs blesses	Nombre de joueurs clés blessés
Classement actuel	Position dans le championnat
Domicile ou Extérieur	L'équipe joue à domicile ou à l'extérieur

Le label (variable de sortie) à prédire est le résultat final du match : Victoire, Défaite ou Nul. Ces données sont objectives et mesurables, ce qui les rend idéales pour l'entraînement d'un modèle.

5.3 Étape 2 et 3 — Division des données et Entraînement

Les 10 000 matchs sont divisés en deux parties selon la règle classique 80/20 :

— 80% soit 8 000 matchs pour l'entraînement : le modèle apprend les patterns des matchs passés

— 20% soit 2 000 matchs pour le test : le modèle est évalué sur des matchs qu'il n'a jamais vus

L'algorithme utilisé est le Random Forest avec 100 arbres de décision. Pour chaque nouveau match, les 100 arbres votent et le résultat majoritaire est retenu comme prédiction finale. Par exemple :

TABLE 5.2 – Exemple de vote majoritaire dans un Random Forest (100 arbres)

Arbre	**Prédiction**
79 arbres sur 100	VICTOIRE
15 arbres sur 100	NUL
6 arbres sur 100	DÉFAITE
Résultat final	VICTOIRE (vote majoritaire)

Les résultats obtenus sont les suivants :

TABLE 5.3 – Résultats globaux du modèle Random Forest (train vs test accuracy)

Métrique	**Valeur**	**Interprétation**
Train Accuracy	89%	Le modèle a bien appris
Test Accuracy	83%	Le modèle généralise bien
Différence	6 points	Faible $\rightarrow$ Pas d'overfitting

La faible différence entre le Train accuracy (89%) et le Test accuracy (83%) confirme que le modèle n'est pas en situation d'overfitting — il a vraiment appris les patterns généraux des matchs.

5.4 Étape 4 — Évaluation du modèle

Le modèle est évalué sur 300 matchs test à l'aide d'une matrice de confusion. Cet outil compare les prédictions du modèle avec les résultats réels.

La matrice de confusion est un tableau où les lignes représentent les résultats réels et les colonnes représentent les prédictions du modèle. Les cases sur la diagonale représentent les

bonnes prédictions, et les autres cases représentent les erreurs.

TABLE 5.4 – Matrice de confusion du modèle de classification des résultats de matchs

Réel/Prédit	**Victoire**	**Défaite**	**Nul**
Victoire	89	8	6
Défaite	7	82	9
Nul	12	10	77

Le calcul de l'accuracy globale est le suivant : Accuracy = (89 + 82 + 77) / 300 = 248 / 300 = 83

On remarque que le modèle commet plus d'erreurs sur les matchs nuls (22 erreurs) que sur les victoires (14 erreurs) ou les défaites (16 erreurs). Cela s'explique par le fait que le résultat Nul est intrinsèquement plus difficile à prédire — un match peut se terminer 0-0 même quand une équipe domine largement, ce qui rend la détection de patterns difficile.

5.5 Applications réelles

Ce type de modèle de prédiction de résultats de football est utilisé dans de nombreux domaines professionnels :

- Sites de paris sportifs (Bet365, Winamax) : calcul automatique des cotes en fonction des probabilités prédites
- Clubs professionnels (Manchester City, Real Madrid) : analyse tactique et préparation des matchs
- Organisations sportives (FIFA, UEFA) : classement des équipes et prédiction des performances
- Médias sportifs (beIN Sports, ESPN) : affichage des probabilités en temps réel pendant les matchs
- Staff médical des clubs : prédiction du risque de blessure des joueurs

conclusion

Le machine learning, et plus spécifiquement l'apprentissage supervisé, constitue un pilier des systèmes intelligents contemporains. Il permet de convertir des données brutes en modèles prédictifs robustes. Dans le cadre de ce projet, une analyse approfondie des fondements a été menée. Le pipeline du machine learning a été examiné en détail. Il débute par la collecte de données hétérogènes et volumineuses. Suit le prétraitement, incluant le nettoyage et la normalisation. L'analyse exploratoire identifie ensuite les corrélations pertinentes. L'entraînement optimise les paramètres du modèle via des algorithmes itératifs. La validation croisée évalue enfin la généralisabilité. Ces étapes interconnectées déterminent la performance globale. Les paradigmes centraux de l'apprentissage supervisé ont été étudiés. La régression linéaire ou logistique modélise des sorties continues ou probabilistes. La classification binaire ou multiclasse discrimine des catégories discrètes. Ces méthodes s'appuient sur des ensembles d'entraînement étiquetés. Le principe clé réside dans la généralisation aux instances inédites. Ainsi, le surapprentissage est évité au profit d'une prédiction fiable. Ce travail établit ainsi les bases théoriques et pratiques pour des avancées en intelligence artificielle.

Bibliographie

[1] Christopher Bishop – Pattern Recognition and Machine Learning

[2] Hastie, Tibshirani, Friedman – The Elements of Statistical Learning

[3] Articles et cours de Machine Learning (MIT, Stanford)

[4] The Elements of Statistical Learning

[5] Pattern Recognition and Machine Learning

[6] Machine Learning : A Probabilistic Perspective